

Especificación de panel de datos

Solicitud para la calibración del modelo predictivo de Oráculo

Solicitante	Lucas Carrasquilla Parra
DNI	1025060974
Plan	MA03 — Matemáticas Aplicadas y Ciencias de la Computación
Semestre	IV (en curso, 2026-1)
Proyecto	Oráculo: planeador académico personalizado con motor estadístico de riesgo
Fecha	4 de mayo de 2026
Versión	1.0

1 Resumen ejecutivo

Este documento especifica los requerimientos de datos para calibrar el motor de riesgo de Oráculo, una plataforma de planeación académica personalizada para estudiantes de la Universidad del Rosario. La solicitud comprende dos bloques complementarios:

1. **Panel histórico de calificaciones:** un panel longitudinal a nivel de matrícula (estudiante $\times$ asignatura $\times$ sección $\times$ semestre) con la calificación final, atributos del estudiante en el momento de matricular y atributos de la sección y el docente.
2. **Panel sociodemográfico:** variables de contexto del estudiante usadas exclusivamente como *controles* del modelo, sin exposición a usuarios finales.

Ambos bloques se entregan anonimizados, en un único archivo o endpoint, para uso del equipo de Oráculo bajo acuerdo de transferencia de datos con la Vicerrectoría de Investigación. Como retorno, la universidad recibe los modelos calibrados, los hallazgos agregados y el código del pipeline.

2 Propósito de uso

Los datos se usarán para tres fines:

- **Modelación predictiva.** Calibrar un modelo logístico (línea base) y un modelo logístico de efectos mixtos (validación) que estimen, para cada estudiante, la probabilidad de reprobar una asignatura cursada con un docente específico, condicional a su perfil académico y a controles sociodemográficos.
- **Recomendación de horario.** Integrar la predicción al optimizador de horarios de Oráculo para penalizar combinaciones de alto riesgo y sugerir intercambios de sección.
- **Investigación.** Producir al menos un manuscrito sobre el efecto del docente en el desempeño estudiantil dentro de la universidad, con identificación robusta y publicación en una revista de economía de la educación o pedagogía universitaria.

3 Unidad de observación

Una fila representa una matrícula: un estudiante en una sección específica de una asignatura en un periodo académico.

```
(student_id_hash, course_code, section_id, semester) → outcome +  
covariables
```

Si un estudiante repite la asignatura en otro semestre, se generan filas separadas. Si una sección tuvo cancelación administrativa, también se incluye, marcada en la variable `enrollment_outcome`.

4 Cobertura solicitada

Dimensión	Mínimo viable	Cobertura ideal
Período	2021-1 al último semestre cerrado	2018-1 en adelante
Programa	Plan MA03 (piloto)	Toda la Escuela de Ciencias e Ingeniería; eventualmente toda la Universidad
Tipología	Asignaturas obligatorias del núcleo	Todas las tipologías (OBL, ELEC, COMP, HM, PFC)

Volumen estimado: aproximadamente 30 a 60 mil filas para el piloto MA03 sobre cinco años; entre 250 y 500 mil filas para la cobertura completa institucional. El tamaño es manejable en una sola entrega.

5 Variables requeridas

Las variables se agrupan en seis bloques. Todas las variables identificatorias se entregan anonimizadas (Sección 6).

5.1 Identificadores

Variable	Tipo	Descripción
<code>student_id_hash</code>	string	Hash estable del DNI con sal mantenida por la oficina de datos. Permite seguir al estudiante en el tiempo sin exponer su identidad.
<code>course_code</code>	string	Código institucional de la asignatura (ej. 11310003).
<code>section_id</code>	string	Identificador de la sección dentro del par (asignatura, semestre).
<code>professor_id_hash</code>	string	Hash estable del docente. Permite efectos fijos de profesor cruzando años y asignaturas.
<code>semester</code>	string	Formato YYYY-N (ej. 2024-1, 2024-2, intersemestral_2025).

5.2 Variables de resultado

Variable	Tipo	Descripción
final_grade	numeric (0,0–5,0)	Calificación final en la escala institucional.
passed	bool	Igual a 1 si final_grade $\geq$ 3,0. Redundante pero conveniente.
enrollment_outcome	enum	completed / withdrew_voluntary / withdrew_administrative / failed_attendance.
withdrew_week	int (nullable)	Semana de la cancelación si aplica.

5.3 Atributos del estudiante en el momento de la matrícula

Estas variables son las *entradas* del modelo. Deben reflejar el estado del estudiante **al inicio del semestre** de la fila, no su estado actual.

Variable	Tipo	Descripción
program_code	string	Plan vigente al matricular (ej. MA03).
cohort_entry_year	int	Año de ingreso a la universidad.
semester_number	int	Número de semestres cursados antes de éste.
credits_completed	int	Créditos aprobados antes de este semestre.
cumulative_gpa	numeric	PGA acumulado al cierre del semestre anterior.
current_load_credits	int	Total de créditos inscritos en el semestre de la fila.
prerequisite_grades	array<numeric> (nullable)	Notas en los prerrequisitos directos. Derivable vía self-join si no está pre-computado.

5.4 Panel sociodemográfico (controles del modelo)

Estas variables se usan **únicamente** como controles en la regresión. No se exponen al usuario final, ni a otros estudiantes, ni se publican en ningún output de la plataforma.

Variable	Tipo	Descripción
gender	enum	M / F / Otro / NA.
birth_year	int	Año de nacimiento (no fecha exacta).
municipality_residence	string	Municipio de residencia, sin dirección.
school_origin_type	enum	público / privado / mixto / internacional.
school_origin_calendar	enum	A / B (calendario académico de origen).
saber11_score	int (nullable)	Puntaje global Saber 11 / ICETEX.
socioeconomic_stratum	int (1–6)	Estrato socioeconómico de la residencia.
scholarship_status	bool	¿Recibe beca o apoyo financiero?
scholarship_type	string (nullable)	Tipo (Pa'lante, Excelencia, ICETEX, etc.).
financial_aid_pct	numeric (0–1, nullable)	Porcentaje de matrícula cubierto.
is_first_generation	bool (nullable)	Si la universidad lo registra.
works_during_studies	bool (nullable)	Si está disponible vía encuesta de bienestar.

Si alguna de estas variables no es trivial de extraer, puede entregarse en una segunda fase. El **bloque mínimo viable** comprende: *gender*, *birth_year*, *school_origin_type*, *saber11_score*, *socioeconomic_stratum* y *scholarship_status*.

5.5 Atributos de la sección y la asignatura

Variable	Tipo	Descripción
course_credits	int	Créditos de la asignatura.
course_typology	enum	OBL / ELEC / COMP / HM / PFC.
course_plan_semester	int (1-8)	Semestre estándar dentro del plan.
school	string	Escuela / Facultad.
section_capacity	int	Cupo máximo.
section_enrolled	int	Inscripción final.
section_modality	enum	presencial / virtual / híbrido.
meeting_pattern	string	Días y horas (ej. MAR 09:00-10:30; JUE 09:00-10:30).

5.6 Atributos del profesor

Variable	Tipo	Descripción
professor_id_hash	string	(mismo hash de identificadores, repetido para join).
professor_years_teaching_at_unit	int	Años en la universidad al inicio del semestre.
professor_highest_degree	enum	pregrado / especialización / maestría / doctorado.
professor_contract_type	enum	planta / hora_cátedra / visitante / medio_tiempo.
professor_home_department	string	Departamento al que está adscrito.

5.7 Atributos del periodo

Variable	Tipo	Descripción
semester_start_date	date	Fecha de inicio del semestre.
semester_end_date	date	Fecha de cierre del semestre.
calendar_disruption_flag	bool	1 si el semestre tuvo paro, ajuste por COVID u otro evento que afectó las calificaciones. La universidad sabrá cuáles.

6 Anonimización

Los siguientes requerimientos son **no negociables** y se pactan por escrito en el acuerdo de transferencia de datos.

1. **Sin PII directa.** No se transfieren nombres, números de documento, correos electrónicos, fechas de nacimiento exactas, direcciones ni teléfonos.

2. **Hashing estable con sal.** Los hashes de estudiante y profesor son deterministas dentro del dataset (para permitir self-joins y panel longitudinal) pero no reversibles. La sal queda en custodia de la oficina de datos y no se comparte con el solicitante.
3. **Supresión de celdas pequeñas.** En cualquier celda donde el cruce (asignatura $\times$ profesor $\times$ semestre) tenga menos de **cinco estudiantes**, la fila se omite o se marca explícitamente. Esta regla previene re-identificación por combinatoria.
4. **No exposición fuera del modelo.** Las variables del panel sociodemográfico (Sección 5.4) jamás se muestran al usuario final ni a otros estudiantes; se usan únicamente como controles del modelo logístico.
5. **Auditoría.** La oficina mantiene un registro de quién accedió, cuándo y desde qué IP. Renovación anual del acuerdo.

7 Formato y entrega

Preferencias de entrega (en orden descendente)

1. Endpoint API autenticado con refresco programado.
2. Volcado periódico a un bucket institucional (S3 o Google Cloud Storage) con acceso restringido al solicitante.
3. Archivo único por cohorte (CSV o Parquet) entregado vía correo institucional cifrado.

Acompañamiento obligatorio

- **Codebook.** Cada variable con tipo, dominio de valores, etiquetas, fuente original y fecha de extracción.
- **Diccionario de mapeos** de códigos institucionales (asignatura, programa, escuela) si difieren del catálogo público.
- **Notas de calidad.** Semestres incompletos, cambios de plan de estudios, migraciones de SIIGRA y otros eventos que afecten la interpretación.

8 Frecuencia de actualización

- **Carga inicial:** desde el periodo más antiguo acordado hasta el último semestre cerrado.
- **Actualización:** una vez al año, después del cierre del segundo semestre (típicamente febrero), agregando los dos semestres más recientes.
- **Catálogo de secciones del semestre vigente:** sincronización por API o scrape público; no requiere acuerdo institucional adicional.

9 Marco legal y ético

- **Acuerdo de transferencia de datos** firmado entre el solicitante y la Vicerrectoría de Investigación (o la dependencia que la oficina indique).

- **Aval del Comité de Ética en Investigación** previo a cualquier salida pública (manuscrito, conferencia, blog).
- Cumplimiento de la **Ley 1581 de 2012** (protección de datos personales en Colombia) y del régimen interno de la Universidad del Rosario.
- **Cláusula de no-reidentificación:** el solicitante se compromete por escrito a no intentar re-identificar a ningún sujeto del panel.

10 Compromiso de devolución

- Los modelos calibrados y los hallazgos agregados se comparten con la universidad antes de cualquier publicación externa.
- El código del pipeline (sin datos) se entrega como repositorio Git al cierre del proyecto.
- La universidad puede usar los modelos resultantes en sus propios sistemas si así lo decide, sin restricción.

11 Pregunta abierta a la oficina de datos

¿Pueden indicar si los bloques de Identificadores, Resultado, Atributos del estudiante en el momento de la matrícula y Atributos de la sección ya se encuentran unidos en SIIGRA, o si requieren un cruce con otras tablas? Saber esto permite estimar el esfuerzo de extracción y proponer una primera entrega piloto solo con MA03.

Documento elaborado para Oráculo / v1.0 / 2026